

CHƯƠNG 6: THỰC NGHIỆM HYBRID SEARCH VỚI TẬP DỮ LIỆU SCIFACT

6.1 Tóm tắt

Thực nghiệm này trình bày quy trình triển khai và đánh giá hiệu suất của các phương pháp truy xuất thông tin (Information Retrieval) trên tập dữ liệu khoa học SciFact. Bằng việc tận dụng cơ sở dữ liệu Oracle 26ai, hệ thống tích hợp và so sánh ba phương pháp: Truy xuất ngữ nghĩa (Semantic Search), Truy xuất từ khóa (Keyword Search) và phương pháp lai (Hybrid Search). Kết quả thực nghiệm trên 300 truy vấn cho thấy Hybrid Search đạt hiệu suất cao nhất với chỉ số Hit@10 đạt 82.33% và Hit@50 đạt 92.00%, chứng minh tính hiệu quả của việc kết hợp từ vựng và ngữ nghĩa trong hệ thống RAG chuyên ngành khoa học.

6.2 Giới thiệu

Trong bối cảnh lượng tài liệu nghiên cứu khoa học tăng trưởng theo cấp số nhân, việc xác minh các luận điểm khoa học (scientific claim verification) trở thành một bài toán cấp thiết. Bài toán này đòi hỏi các hệ thống xử lý ngôn ngữ tự nhiên (NLP) không chỉ hiểu ngữ nghĩa chuyên sâu mà còn phải truy xuất chính xác các tài liệu làm bằng chứng (evidence abstracts).

Quá trình truy xuất thường gặp khó khăn do sự phức tạp của từ vựng chuyên ngành và các biến thể đồng nghĩa. Để giải quyết vấn đề này, Oracle 26ai Database cung cấp nền tảng AI Vector Search cho phép thực hiện tìm kiếm ngữ nghĩa và tìm kiếm văn bản (Full-text search) trên cùng một hệ quản trị cơ sở dữ liệu duy nhất. Nghiên cứu này triển khai một pipeline truy xuất toàn diện trên tập dữ liệu SciFact nhằm đánh giá và tìm ra chiến lược tối ưu nhất để trích xuất bằng chứng khoa học cho các mô hình Retrieval-Augmented Generation (RAG). Toàn bộ mã nguồn thực nghiệm ở <https://github.com/24520152-ben/Hybrid-Search-SciFact-Oracle-26ai-Database>.

6.3 Bối cảnh

- **Tập dữ liệu SciFact:** SciFact là tập dữ liệu chuyên biệt cho bài toán xác minh luận điểm khoa học. Tập dữ liệu bao gồm 1,409 luận điểm khoa học được các chuyên gia chú thích, đi kèm với kho ngữ liệu gồm 5,183 tài liệu (abstracts) chứa các câu bằng chứng hỗ trợ (SUPPORTS) hoặc bác bỏ (REFUTES) luận điểm.
- **Oracle AI Vector Search & LangChain Integration:** Đây là một công nghệ cơ sở dữ liệu tích hợp hiện đại, hỗ trợ tìm kiếm vector (dựa trên ý nghĩa ngữ nghĩa) kết hợp với lọc quan hệ truyền thống. Thông qua tích hợp `langchain-oracledb`, lập trình viên có thể dễ dàng quản lý vòng đời tài liệu, tạo các chỉ mục như HNSW (Hierarchical Navigable Small World), và thực hiện các câu lệnh tìm kiếm nâng cao trực tiếp bằng Python.

6.4 Phương pháp

Quy trình thực nghiệm được xây dựng bằng ngôn ngữ Python, sử dụng thư viện LangChain để tương tác trực tiếp với Oracle Database thông qua driver `oracledb` chạy ở chế độ Thin mode.

6.4.1 Data Ingestion & Preprocessing

Kho ngữ liệu gồm 5,183 tài liệu ban đầu từ corpus của SciFact được xử lý theo pipeline sau:

1. **Text Chunking:** Sử dụng thuật toán `RecursiveCharacterTextSplitter` với cấu hình `chunk_size = 500` và `chunk_overlap = 50`. Quá trình này chia nhỏ kho ngữ liệu thành 18,168 đoạn (chunks), mỗi đoạn được cấp một UUID ngẫu nhiên đồng thời lưu giữ `corpus_id` nguyên bản của tài liệu gốc.
2. **Vector Embedding:** Chuyển đổi toàn bộ các đoạn văn bản thành không gian vector mật độ cao bằng mô hình `sentence-transformers/all-MiniLM-L6-v2`. Quá trình mã hóa sử dụng chuẩn hóa kích thước vector (`normalize_embeddings = True`).
3. **Database Ingestion:** Dữ liệu được đẩy vào bảng `SciFact` trong Oracle Database theo từng batch với kích thước `BATCH_SIZE = 500`. Chiến lược tính khoảng cách được thiết lập là `DistanceStrategy.COSINE`.

6.4.2 Retrieval Pipelines

Nghiên cứu tiến hành xây dựng và đối chiếu ba chiến lược truy xuất để lấy ra top k tài liệu phù hợp nhất:


1. **Semantic Search (Truy xuất ngữ nghĩa):** Khởi tạo chỉ mục cấu trúc đồ thị HNSW trên cột chứa vector với tên `hnsw_scifact`. Hệ thống sử dụng `VectorStoreRetriever` để thực hiện tìm kiếm độ tương đồng (`search_type="similarity"`).
2. **Keyword Search (Truy xuất từ khóa):** Khởi tạo chỉ mục văn bản hệ thống Oracle Text mang tên `keyword_scifact`. Sử dụng thành phần `OracleTextSearchRetriever` kết hợp tham số `fuzzy=True` nhằm kích hoạt tính năng khớp từ gần đúng, giúp sửa lỗi chính tả và nâng cao độ phủ.
3. **Hybrid Search (Truy xuất hỗn hợp):** Chiến lược lai kết hợp kết quả trả về của cả hai phương pháp trên. Hệ thống thực hiện lấy hợp (Union) danh sách các `corpus_id` trích xuất được từ Semantic Search và Keyword Search tại cùng một cấu hình ngưỡng k .

6.5 Thực nghiệm & Kết quả

Hệ thống được đánh giá thực nghiệm nghiêm ngặt trên toàn bộ 300 câu truy vấn thuộc tập kiểm thử (test set) của SciFact. Quá trình đánh giá áp dụng hàm `ChunksToDocuments` để ánh xạ các đoạn văn bản (chunks) được mô hình lấy ra về lại mã tài liệu gốc (`corpus_id`). Một câu truy vấn được ghi nhận là chính xác (Hit) nếu mã tài liệu chuẩn nằm trong danh sách các tài liệu được hệ thống truy xuất.

Dựa vào kết quả thu được tại Hình 6.1, Semantic Search thể hiện sự vượt trội rõ rệt so với Keyword Search truyền thống, với mức chênh lệch hiệu suất luôn duy trì từ 10% đến hơn 13% ở tất cả các mốc k . Điều này chứng minh rằng trong miền tri thức khoa học, việc nắm bắt ngữ cảnh và ý niệm chuyên sâu đóng vai trò rất quan trọng.

Đáng chú ý, phương pháp Hybrid Search đạt được kết quả tối ưu nhất ở mọi cấu hình thực nghiệm. Tại mốc **Hit@10**, Hybrid Search giúp nâng hiệu suất lên **82.33%**. Khi mở rộng không gian tìm kiếm lên **Hit@50**, mô hình lai đạt tỷ lệ chính xác ấn tượng lên đến **92.00%**. Kết quả này chứng minh tính bổ trợ mạnh mẽ giữa cơ chế so khớp từ vựng chính xác của Oracle Text và cơ chế hiểu ngữ nghĩa của AI Vector Search.



Hình 6.1: Xu hướng thay đổi hiệu suất truy xuất khi tăng tham số k .

6.6 Kết luận

Thực nghiệm đã chứng minh tính hiệu quả vượt trội khi ứng dụng hệ quản trị cơ sở dữ liệu thể hệ mới Oracle 26ai kết hợp thư viện LangChain để giải quyết bài toán truy xuất thông tin trên tập dữ liệu khoa học phức tạp SciFact. Giải pháp Hybrid Search tích hợp trực tiếp trong một hệ thống lưu trữ duy nhất không chỉ đơn giản hóa kiến trúc hạ tầng dữ liệu RAG mà còn đem lại độ chính xác cực kỳ cao.